Arquitectura de datos para FarmIA en Azure

Mateo Arenas Montoya

Resumen

Este documento describe la arquitectura de datos propuesta para FarmIA en Microsoft Azure. La solución se basa en el paradigma Lakehouse con Delta Lake y el patrón Medallion. La elección no es arbitraria: FarmIA necesita triplicar su capacidad de datos en dos años, conectar fuentes muy distintas entre sí (sensores de campo, sistemas de inventarios, apps móviles) y tomar decisiones operativas en tiempo real. Una arquitectura monolítica tradicional no aguantaría ese ritmo.

Requerimientos y contexto

FarmIA está en plena expansión nacional y tiene cuatro problemas que resolver al mismo tiempo:

Requisito	**Descripción del Desafío**	**Solución Propuesta**
Escalabilidad	Crecimiento proyectado de 3x en el volumen de datos.	Almacenamiento desacoplado del cómputo con ADLS Gen2.
Integración	Fuentes heterogéneas: IoT, SQL, APIs, Móvil.	Orquestación unificada con Azure Data Factory e IoT Hub.
Analítica Avanzada	Optimización de logística y predicción de cultivos.	Procesamiento con Spark y modelos en Azure Machine Learning.
Tiempo Real	Decisiones operativas inmediatas.	Ingesta con Event Hubs y análisis en streaming.

Justificación técnica de la arquitectura

Escalabilidad

ADLS Gen2 almacena datos estructurados y no estructurados a un costo razonable. Lo más importante es que el cómputo corre separado del almacenamiento mediante Azure Databricks:

cuando hay picos de carga, se escala el cómputo sin tocar el storage, y cuando el pico pasa, se reduce. Eso evita pagar por capacidad que rara vez se usa.

Integración

Azure Data Factory conecta el sistema de inventarios local con la nube sin necesidad de migrar todo de golpe. Los sensores de campo se conectan a través de Azure IoT Hub, que además de recibir telemetría puede enviar comandos a los dispositivos, algo útil si en el futuro se quiere controlar riego o alertas automáticas desde la plataforma.

Delta Lake y la capa de analítica

Los Data Lakes tienen fama de convertirse en pantanos de datos sin gobierno. Delta Lake lo evita con tres mecanismos concretos:

- *Transacciones ACID*: una escritura fallida no deja datos corruptos a medias.
- *Time Travel*: permite ver cómo estaban los datos en cualquier momento anterior, útil para auditorías y para depurar errores.
- *Medallion Architecture*: los datos pasan por tres capas (Bronze, Silver, Gold), de modo que analistas y científicos de datos siempre trabajan con el nivel de calidad que necesitan, no con el crudo sin procesar.

Componentes y flujo

Origen

- *Fuentes Externas*: Sensores IoT en campos, Base de Datos SQL de Inventarios, APIs de ventas de terceros y eventos de Aplicaciones Móviles.

Ingesta

- *Azure IoT Hub*: Captura de telemetría de sensores.
- *Azure Event Hubs*: Captura de eventos de aplicaciones en tiempo real.
- *Azure Data Factory*: Orquestación de cargas batch desde sistemas SQL y APIs.

Almacenamiento (Delta)

- *Bronze (Raw)*: Almacenamiento inmutable de datos tal cual llegan.
- *Silver (Cleaned)*: Datos normalizados, sin duplicados y con tipos de datos corregidos.
- *Gold (Aggregated)*: Tablas optimizadas para el negocio (ventas por región, eficiencia logística).

Procesamiento

- *Azure Databricks / Synapse Spark*: Motor principal de transformación que ejecuta la lógica de negocio y prepara los datos para el consumo.

Servicios y Consumo

- *Azure Synapse SQL*: Sirve los datos de la capa Gold a través de un almacén de datos relacional de alto rendimiento.
- *Power BI*: Visualización de KPIs y dashboards operativos.
- *Azure Machine Learning*: Generación de predicciones logísticas integradas en aplicaciones personalizadas.

Implementación

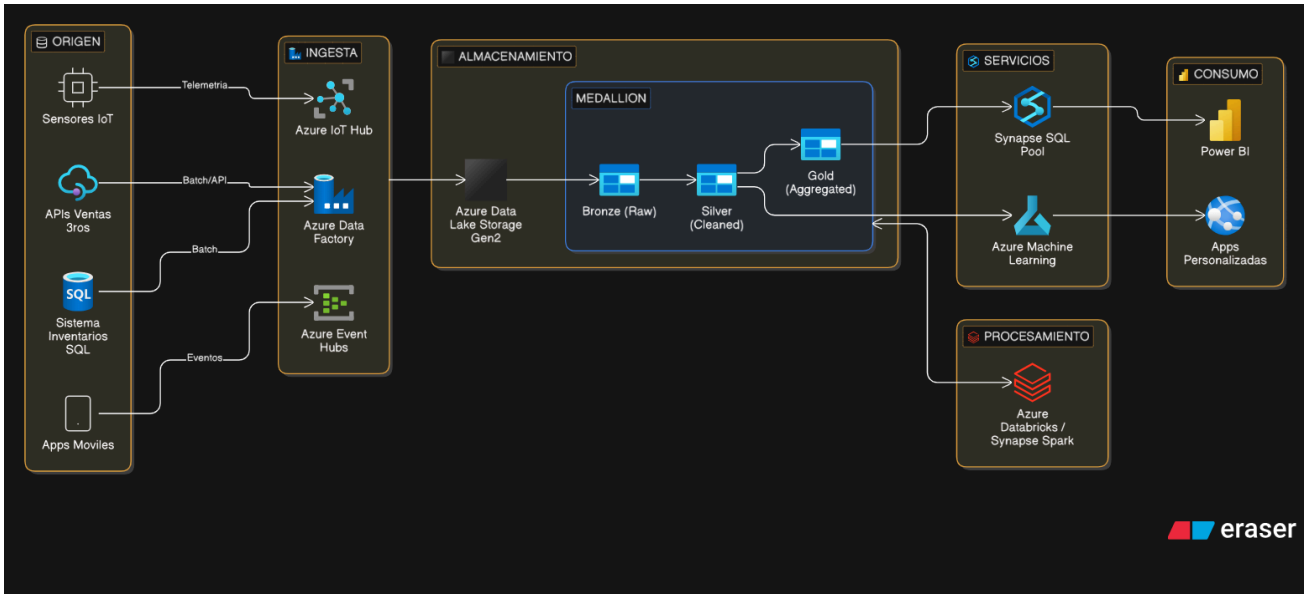

Bibliografía

Arquitecturas y Metodologías de Datos

- Microsoft Learn. *What is the medallion lakehouse architecture?* Guía oficial sobre capas Bronze, Silver y Gold en Azure Databricks. Disponible en: https://learn.microsoft.com/en-us/azure/databricks/lakehouse/medallion
- Microsoft Learn. *Azure Databricks Modern Data Warehouse Architecture.* Arquitectura de referencia para analítica avanzada. Disponible en: https://learn.microsoft.com/en-us/azure/architecture/solution-ideas/articles/azure-databricks-modern-data-warehouse-architecture
- Microsoft Fabric Blog. *From Lakehouse to boardroom: Analytics and AI for real insights.* Evolución de arquitecturas Lakehouse 2024-2026. Disponible en: https://blog.fabric.microsoft.com/en-us/blog/from-lakehouse-to-boardroom-analytics-and-ai-for-real-insights

Almacenamiento y Protocolos

- Microsoft Azure. *Azure Data Lake Storage Gen2.* Introducción al almacenamiento en la nube para Big Data. Disponible en: https://azure.microsoft.com/es-es/products/storage/data-lake-storage
- Delta Lake Project. *Delta Lake Documentation.* Protocolo de almacenamiento y transacciones ACID. Disponible en: https://docs.delta.io/latest/index.html

Ingesta y Streaming de Datos

- Microsoft Azure. *Azure IoT Hub.* Gestión de telemetría y dispositivos a escala. Disponible en: https://azure.microsoft.com/es-es/products/iot-hub
- Microsoft Learn. *Azure Event Hubs.* Plataforma de streaming de datos masivos. Disponible en: https://learn.microsoft.com/en-us/azure/event-hubs/event-hubs-about

Inteligencia Artificial y Herramientas de Productividad

- Manus AI. Agente de inteligencia artificial general. Disponible en: https://manus.ai
- Eraser.io. Herramienta de diagramación técnica y documentación visual. Disponible en: https://app.eraser.io/